Faire du Stacking avec Titanic

On va faire notre premier stacking ensemble. Voyons comment cela peut améliorer notre score sur le dataset du Titanic

1. Importez les librairies usuelles

In [1]: import pandas as pd

2. Importez le dataset dans un DataFrame

In [2]: df=pd.read_csv('C:/Users/dell/Desktop/titanic.csv')

In [3]: df.head()

Out[3]

]:		PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
	0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
	1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th	female	38.0	1	0	PC 17599	71.2833	C85	С
	2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
	3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
	4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

3. Remplacez la colonne

name Ticket

Par le nombre de caractères qu'il y a dans la cellule

```
In [4]: df['Name'] = df['Name'].apply(lambda x: len(str(x)))
    df['Ticket'] = df['Ticket'].apply(lambda x: len(str(x)))
    df.head()
```

Out[4]:		PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
	0	1	0	3	23	male	22.0	1	0	9	7.2500	NaN	S
	1	2	1	1	51	female	38.0	1	0	8	71.2833	C85	С
	2	3	1	3	22	female	26.0	0	0	16	7.9250	NaN	S
	3	4	1	1	44	female	35.0	1	0	6	53.1000	C123	S
	4	5	0	3	24	male	35.0	0	0	6	8.0500	NaN	S

4. Créez une nouvelle colonne FamilySize qui sera la somme des colonnes SibSp & Parch

Out[5]:		PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	FamilySize
	0	1	0	3	23	male	22.0	1	0	9	7.2500	NaN	S	1
	1	2	1	1	51	female	38.0	1	0	8	71.2833	C85	С	1
	2	3	1	3	22	female	26.0	0	0	16	7.9250	NaN	S	0
	3	4	1	1	44	female	35.0	1	0	6	53.1000	C123	S	1
	4	5	0	3	24	male	35.0	0	0	6	8.0500	NaN	S	0

5. Créez une nouvelle colonne IsAlone qui indique si la personne a une famille ou non

Out[6]:		Passengerld	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	FamilySize	IsAlone
	0	1	0	3	23	male	22.0	1	0	9	7.2500	NaN	S	1	1
	1	2	1	1	51	female	38.0	1	0	8	71.2833	C85	С	1	1
	2	3	1	3	22	female	26.0	0	0	16	7.9250	NaN	S	0	0
	3	4	1	1	44	female	35.0	1	0	6	53.1000	C123	S	1	1
	4	5	0	3	24	male	35.0	0	0	6	8.0500	NaN	S	0	0

6. Dans la colonne Cabin Faites en sorte de ne garder uniquement la première lettre de la cabine

Out[7]:		PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	FamilySize	IsAlone
	0	1	0	3	23	male	22.0	1	0	9	7.2500	NaN	S	1	1
	1	2	1	1	51	female	38.0	1	0	8	71.2833	С	С	1	1
	2	3	1	3	22	female	26.0	0	0	16	7.9250	NaN	S	0	0
	3	4	1	1	44	female	35.0	1	0	6	53.1000	С	S	1	1
	4	5	0	3	24	male	35.0	0	0	6	8.0500	NaN	S	0	0

7. Faites une interpolation linéaire pour remplacer les valeurs manquantes dans la colonne Age

```
In [8]: df['Age'] = df['Age'].interpolate(method='linear')
df.head()
```

Out[8]:		PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	FamilySize	IsAlone
	0	1	0	3	23	male	22.0	1	0	9	7.2500	NaN	S	1	1
	1	2	1	1	51	female	38.0	1	0	8	71.2833	C	С	1	1
	2	3	1	3	22	female	26.0	0	0	16	7.9250	NaN	S	0	0
	3	4	1	1	44	female	35.0	1	0	6	53.1000	С	S	1	1
	4	5	0	3	24	male	35.0	0	0	6	8.0500	NaN	S	0	0

8. Comptez le nombre de NaN qu'il y a dans la colonne Embarked et adoptez la stratégie qui vous semble le plus adapté pour gérer ces valeurs

```
In [9]: | nan_count = df['Embarked'].isna().sum()
         print(f"Nombre de NaN dans la colonne 'Embarked': {nan_count}")
        Nombre de NaN dans la colonne 'Embarked': 2
In [10]:
         most_frequent_embarked = df['Embarked'].mode()[0]
         df['Embarked'].fillna(most frequent embarked, inplace=True)
In [11]:
         df.head()
Out[11]:
            Passengerld Survived Pclass Name
                                                  Sex Age SibSp Parch Ticket
                                                                                    Fare Cabin Embarked FamilySize IsAlone
          0
                                                                                                        S
                      1
                                      3
                                             23
                                                       22.0
                                                                 1
                                                                        0
                                                                                  7.2500
                                                                                           NaN
                                                                                                                   1
                                                  male
                                                                               9
                                                                                                                           1
                                            51 female 38.0
          1
                      2
                                      1
                                                                 1
                                                                       0
                                                                               8 71.2833
                                                                                             C
                                                                                                        C
                                                                                                                           1
                                                                                 7.9250
          2
                                      3
                                            22 female 26.0
                                                                 0
                                                                       0
                                                                                           NaN
                                                                                                        S
                                                                                                                   0
                                                                                                                           0
                                                female 35.0
                                                                                 53.1000
          3
                                      1
                                                                 1
                                                                        0
                                                                                             C
                                                                                                        S
                                                                                                                           1
                      5
                                                                                  8.0500
                               0
                                      3
                                                                       0
                                                                                                        S
                                                                                                                   0
                                                                                                                           0
                                             24
                                                  male 35.0
                                                                 0
                                                                                           NaN
```

9. Dummyfiez les variables catégoriques

```
In [12]: df = pd.get_dummies(df, columns=['Sex', 'Embarked', 'Cabin'], drop_first=True)
    df.head()
```

Out[12]:		PassengerId	Survived	Pclass	Name	Age	SibSp	Parch	Ticket	Fare	FamilySize	•••	Sex_male	Embarked_Q	Embarked _.
	0	1	0	3	23	22.0	1	0	9	7.2500	1		1	0	
	1	2	1	1	51	38.0	1	0	8	71.2833	1		0	0	
	2	3	1	3	22	26.0	0	0	16	7.9250	0		0	0	
	3	4	1	1	44	35.0	1	0	6	53.1000	1		0	0	
	4	5	0	3	24	35.0	0	0	6	8.0500	0		1	0	

5 rows × 21 columns

10. Séparez votre dataset en X & y qui sont respectivement les variables explicatives et la variable cible

```
In [13]: X = df.drop('Survived',axis=1)
y = df['Survived']
```

11. Normalisez votre dataset

```
In [14]: from sklearn.preprocessing import StandardScaler
    scaler = StandardScaler()
    X_normalized = scaler.fit_transform(X)
```

12. Faites un train_test_split

```
In [15]: from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X_normalized, y, test_size=0.2, random_state=0)
```

13. Faites une première prédiction grâce à une régression logistique et regardez votre score

```
In [16]: from sklearn.linear_model import LogisticRegression
```

```
from sklearn.metrics import accuracy_score
         logistic_model = LogisticRegression()
         logistic_model.fit(X_train, y_train)
         y_pred = logistic_model.predict(X_test)
         accuracy = accuracy_score(y_test, y_pred)
         print(f"Score de la régression logistique : {accuracy}")
        Score de la régression logistique : 0.8044692737430168
          14. Faites une prédiction pour tout votre dataset X et concaténez ces prédiction dans un dataframe qu'on appellera X_new
In [17]: all predictions = logistic model.predict(X normalized)
In [18]: X new = pd.DataFrame({'Logistic Predictions': all predictions})
          15. Faites un nouveau train test split sur X new
In [19]: X_new_train, X_new_test, y_train, y_test = train_test_split(X_new, y, test_size=0.2, random_state=0)
          15. Importez Adaboost et entrainez votre nouveau modèle sur X new
In [20]:
         from sklearn.ensemble import AdaBoostClassifier
         adaboost model = AdaBoostClassifier()
         adaboost_model.fit(X_new_train, y_train)
         y_new_pred = adaboost_model.predict(X_new_test)
          16. Regardez votre nouveau score
In [21]: | accuracy_new = accuracy_score(y_test, y_new_pred)
         print(f"Score avec Adaboost : {accuracy_new}")
        Score avec Adaboost: 0.8044692737430168
```